

Paper Summary

Title

Belief-Guided State Verification for Planning under Partial Observability

부분 관측 환경의 로봇이 외부 정보를 언제 요청하고 무엇을 물을지를 symbolic state belief에 기반해 결정하는 online planning 방법을 제안한다.

Abstract

부분 관측 환경에서 작업하는 로봇은 인식 오류, 행동 실패, 환경 변화로 인해 현재 상태를 하나로 확정하지 못할 수 있다. 이 모호함을 해소하지 않고 계획을 실행하면 잘못된 행동으로 이어질 수 있지만, 모든 불확실성을 외부에 확인하면 질문 비용이 커진다. 본 연구는 이를 부분 관측 symbolic planning에서의 선택적 정보 획득 문제로 정의한다.

제안 방법은 행동과 관측 후 도달 가능한 symbolic world들의 가중 belief를 구성한다. 정규화된 entropy로 belief confidence를 계산하고, confidence가 임계값보다 낮을 때만 외부 정보를 요청한다. 질문이 필요하면 답변 후의 기대 entropy를 가장 크게 줄이는 grounded symbolic fact를 선택해 참·거짓을 묻는다. 답변과 모순되는 상태 가설을 제거한 뒤, 갱신된 belief를 사용해 로봇이 다음 행동을 다시 계획한다.

폐기물 분류와 토마토 수확 도메인에서 평가를 수행한다. 실험은 정확한 답변을 제공하는 Oracle 평가, 시각·언어 모델이 답변하는 VLM 평가, 5명의 참여자가 답변하는 인간 평가로 구성한다. Oracle 평가는 threshold, When-What ablation, 전체 방법 비교를 통해 질문 정책 자체를 분석한다. VLM과 인간 평가는 Ours와 KnowNo만을 비교해, 정확한 oracle 답변에서 관찰한 경향이 현실적인 외부 정보원에서도 유지되는지를 확인한다.

Problem

계획 문제를 $\mathcal{P} = \langle \mathcal{F}, \mathcal{A}, s_0, \mathcal{G} \rangle$ 로 표현한다. $\mathcal{F}$ 는 grounded symbolic fact의 집합, $\mathcal{A}$ 는 precondition과 effect를 갖는 행동 집합, s_0 는 초기 상태, $\mathcal{G}$ 는 목표 조건이다. 고전적 계획과 달리, 행동 결과와 관측이 불확실하므로 로봇은 여러 후속 상태에 대한 belief를 갖는다.

이 연구의 핵심 문제는 작업 성공률을 높이면서 외부 정보 획득 비용을 줄이기 위해 다음 두 결정을 어떻게 내릴 것인가이다.

- 언제 질문할 것인가: 남은 상태 모호함이 후속 계획에 위험할 때를 판단해야 한다.
- 무엇을 질문할 것인가: 남은 상태 가설을 효율적으로 구분하는 planning-relevant fact를 선택해야 한다.

질문은 다음 행동을 지시받는 행동 위임이 아니라, 현재 world state의 특정 fact를 확인하는 정보 행동이다. 답변 후의 행동 선택은 계속 로봇 planner가 담당한다.

Research Questions

- 작업 수행 중 어떤 상태 불확실성이 추가 정보 요청을 필요로 하는가?
- 잘못된 행동을 피하고 계획을 진행하기 위해 어떤 symbolic fact를 확인해야 하는가?
- 질문 시점과 질문 내용을 각각 바꾸었을 때 작업 성공률, 질문 수, 물리 행동 수는 어떻게 달라지는가?

Hypotheses

- 상태 belief의 불확실성으로 질문 시점을 결정하면, 행동 후보의 모호함이나 질문의 기대 누적 보상에 따라 질문하는 방법보다 높은 작업 성공률을 달성할 것이다.

- 기대 정보 이득으로 상태 질문을 선택하면, 행동 선택을 직접 요청하는 방법보다는 질문이 많지만 작업 보상으로 상태 질문을 선택하는 방법보다는 적은 질문으로 필요한 상태 정보를 확보할 것이다.
- 질문으로 정확해진 상태 판단은 잘못된 행동과 복구 행동을 줄여, 목표에 도달하기 위한 물리 행동 수를 줄일 것이다.

Method

로봇은 POMDP $\langle \mathcal{S}, \mathcal{A}, T, R, \Omega, O, \gamma \rangle$ 와 symbolic action model을 사용하며, POMCP로 다음 물리 행동을 선택한다. 제안 방법은 POMCP를 대체하는 새 planner가 아니라, 행동과 관측 후에 belief를 정제하는 정보 획득 계층이다.

1. 현재 planning state s_t^K 에서 행동 a_t 를 실행하고 관측 o_{t+1} 을 얻는다.
2. 전이 모델이 생성한 도달 가능한 후속 symbolic state들만으로 local frontier를 구성한다.
3. 각 상태의 가중치를 $T(s' | s_t^K, a_t)O(o_{t+1} | s', a_t)$ 에 비례하게 계산하고 정규화한다.
4. belief entropy를 상태 가설 수에 따라 정규화해 confidence를 계산한다.
5. confidence가 임계값 τ 보다 낮으면 질문을 시작한다.
6. frontier 상태 사이에서 참값이 다른 fact들 중 기대 posterior entropy가 가장 작은 fact를 선택한다.
7. 외부 답변과 모순되는 가설을 제거하고 가중치를 다시 정규화한다. confidence가 τ 에 도달할 때까지 필요하면 추가로 질문한다.
8. 남은 가설 중 MAP state를 다음 planning state로 채택하고 POMCP planning을 계속한다.

질문 시점에 사용하는 confidence는 다음과 같다.

$$\text{Conf}(\mathcal{B}) = 1 - \frac{\mathcal{H}(\mathcal{B})}{\log_2 |\mathcal{B}|}.$$

질문 내용은 다음의 기대 정보 이득을 최대화하도록 선택한다.

$$c^* = \arg \max_{c \in \mathcal{C}(\mathcal{B})} \left[\mathcal{H}(\mathcal{B}) - \sum_{y \in \{0,1\}} P(y | \mathcal{B}, c) \mathcal{H}(\mathcal{B}^{c,y}) \right].$$

Experimental Evaluation

Domains

실험은 불확실성 구조가 다른 두 계획 도메인에서 수행한다.

- 폐기물 분류: 로봇이 물체를 일반, 종이, 캔, 플라스틱 중 하나로 판별하고 올바른 통에 옮긴다. 불확실성이 주로 물체 카테고리에 집중되므로, 카테고리가 해소되면 후속 pick-and-place 계획은 비교적 단순해진다.
- 토마토 수확: 로봇이 줄기 사이를 이동하며 토마토를 탐지·집기·스캔한 뒤, 익은 토마토는 수확하고 썩은 토마토는 폐기한다. 객체 정체, 위치, 숙성도, 스캔 결과의 불확실성이 여러 결정 단계에 분산되어 있으므로 더 긴 planning horizon과 상태 의존성을 갖는다.

Evaluation Structure

전체 평가는 외부 정보원에 따라 세 부분으로 구성한다.

평가	외부 정보원	비교 방법	주요 목적
Oracle	실제 환경 상태에 접근하는 정확한 답변	threshold, random ablation, policy ablation, 전체 baseline	질문 시점과 내용 정책의 기능적 효과 분리

평가	외부 정보원	비교 방법	주요 목적
VLM	시각·언어 모델의 응답	Ours, KnowNo	불완전한 모델 답변에서 state query와 action query 비교
Human	5명의 참여자 응답	Ours, KnowNo	실제 사용자가 상태 확인과 행동 선택을 수행할 때의 차이 확인

Oracle 실험은 질문 정책의 내적 기능을 분리하는 핵심 planning 평가이다. VLM과 인간 실험은 비교 범위를 Ours와 KnowNo로 제한하여, state-level verification과 action-level selection의 차이에 집중한다.

Oracle Evaluation

Common Protocol

Oracle은 Ours의 binary state query에 진실값을 답하고, 행동 선택형 방법에서는 정답 행동이 후보에 있으면 그 행동을 선택한다. 이를 통해 응답 오류나 응답 시간의 영향을 제거하고, planner와 질문 정책의 성능을 측정한다.

항목	설정
도메인	폐기물 분류, 토마토 수확
장면	도메인별 5개
반복	조건·도메인·장면별 40회
조건당 실행	2개 도메인 × 5개 장면 × 40회 = 400 episode
기본 설정	$\gamma = 0.2$, POMCP simulation 100회, $\tau = 0.8$
제한	최대 50 step, 탐색 깊이 20, UCB $c = 1.0$
주요 지표	성공률, 질문 수, 물리 행동 수, wall-clock time

같은 domain·scene·iteration의 비교 조건에는 같은 초기 seed를 사용한다. 다만 정책이 다른 행동을 선택한 뒤에는 상태 전이와 난수 소비 경로가 달라질 수 있다. 성공률은 모든 episode를 분모로 계산하고, 질문·행동 효율은 실패의 조기 종료 효과를 줄이기 위해 성공한 episode를 기준으로 해석한다.

Threshold Sweep

`00_threshold` 실험은 Ours의 confidence threshold τ 를 0.0에서 1.0까지 0.1 단위로 변화시킨다. When은 $\text{Conf}(\mathcal{B}) < \tau$ 일 때 질문을 시작하고, What은 모든 조건에서 EIG 기반 선택으로 고정한다. 11개 threshold에서 조건당 400회씩 총 4,400 episode를 수행했으며 모두 유효하게 집계되었다.

τ	성공/전체	성공률	성공 episode당 질문 수
0.0	214/400	53.50%	0.00
0.1	212/400	53.00%	0.94
0.2	213/400	53.25%	0.97
0.3	213/400	53.25%	1.28

τ	성공/전체	성공률	성공 episode당 질문 수
0.4	285/400	71.25%	3.63
0.5	293/400	73.25%	4.21
0.6	292/400	73.00%	4.96
0.7	385/400	96.25%	7.53
0.8	388/400	97.00%	8.46
0.9	399/400	99.75%	9.37
1.0	400/400	100.00%	16.98

Threshold 0.0–0.3에서는 질문이 거의 발생하지 않고 성공률이 약 53%에 머물렀다. 0.7부터 성공률이 96% 이상으로 상승했으며, 0.8은 97.0%의 성공률과 8.46회의 질문을 기록했다. 1.0은 100%를 달성했지만 질문이 16.98회로 늘어났다. 따라서 0.8을 보편적 최적값으로 주장하는 대신, 높은 성공률과 제한된 질문 비용 사이의 후속 실험용 operating point로 선택한다.

When–What Ablation

[01_when_what_random](#)과 [02_when_what_policy_ablation](#)은 하나의 subsection에서 설명한다. 전자는 Ours의 When과 What을 random으로 바꾸는 최소 기능 분해이고, 후자는 이를 CP 및 action-value 기반 정책으로 교체하는 구조화된 baseline ablation이다.

Random Ablation

When과 What을 Ours 또는 random으로 설정한 2×2 실험이다. Random When은 각 물리 step에서 0.4의 확률로 질문을 시작하고, Random What은 belief 내 상태마다 참값이 다른 fact 중 하나를 무작위로 선택한다. 각 조건을 400회씩, 총 1,600 episode 수행했으며 모든 결과가 유효하다.

조건	When	What	성공률	성공 episode당 질문 수
Random	Random	Random	73.50%	9.65
What only	Random	EIG	73.50%	7.04
When only	belief confidence	Random	98.75%	13.96
Ours	belief confidence	EIG	98.75%	8.47

Random What을 고정하고 proposed When을 적용하면 성공률이 73.50%에서 98.75%로 25.25%p 상승한다. Proposed What을 고정해도 같은 상승이 나타난다. 반면 proposed When을 고정하고 Random What을 EIG로 바꾸면 성공률은 98.75%로 유지되면서 질문이 13.96회에서 8.47회로 5.50회, 약 39.4% 감소한다. 이는 When이 주로 실패 방지에, What이 주로 질문 효율에 기여함을 보여준다.

Policy Ablation

Random보다 구조화된 대안과 비교하기 위해 Ours의 When 또는 What 하나만을 교체한다. CP-When은 KnowNo의 action conformal prediction set이 비어 있거나, 여러 행동을 포함하거나, fallback을 포함할 때 질문을 시작한다.

Value-When은 최대 query-action Q-value가 최대 physical-action Q-value보다 클 때 질문한다. Value-What은 Ours의 threshold timing을 유지하되 query-action value가 가장 높은 fact를 선택한다.

조건	When	What	성공/전체	성공률	성공 episode당 질문 수
Ours	belief confidence	EIG	396/400	99.00%	8.49
CP-When	action prediction set	EIG	274/400	68.50%	5.69
Value-When	query-action value	EIG	241/400	60.25%	1.28
Value-What	belief confidence	query-action value	393/400	98.25%	12.84

총 1,600 실행 slot 중 1,596개가 정상 파싱되었고, CP-When의 action-option 파싱 오류 4건은 task failure로 성공률 분모에 포함했다. CP-When과 Value-When은 질문 수는 적지만 Ours보다 성공률이 각각 30.5%p, 38.75%p 낮다. Value-What은 Ours와 유사한 성공률을 보였고 paired 차이 0.75%p는 유의하지 않았지만, Ours가 성공 episode당 4.35회 적게 질문했다. 따라서 시점 정책은 성공률, 내용 정책은 질문 횟수에 더 직접적으로 연결된다.

Overall System Comparison

03_baseline은 완성된 Ours를 Query-Action POMDP, KnowNo, IntroPlan과 비교한다. Query-Action POMDP는 질문을 물리 행동과 같은 action space에 넣고 기대 누적 보상으로 선택한다. KnowNo와 IntroPlan은 보정된 행동 후보를 생성하고, 후보가 하나로 정해지지 않을 때 외부에 다음 행동을 선택해 달라고 요청한다. 추가로 Query-Action의 parameter search에서 선택한 domain-specific γ 와 질문 비용 0을 적용한 tuned 조건을 포함한다.

방법	성공/전체	전체 성공률	성공 episode당 질문 수
Ours	390/400	97.50%	8.51
Query-Action original	218/400	54.50%	1.22
KnowNo	224/400	56.00%	2.91
IntroPlan	219/400	54.75%	4.20
Query-Action selected	289/400	72.25%	19.25

Ours는 original Query-Action, KnowNo, IntroPlan보다 41.5–43.0%p 높은 성공률을 보였다. 세 방법은 성공 episode에서도 질문 수가 적지만, 전체 성공률이 54.5–56.0%에 머물러 Ours와 동일한 reliability를 더 적은 질문으로 달성했다고 볼 수 없다. Query-Action selected는 성공률을 72.25%로 높였지만, 질문은 19.25회로 늘어났다. Ours는 이 조건보다 성공률이 25.25%p 높고 성공 episode당 질문은 10.74회 적었다.

VLM Evaluation

VLM 실험은 oracle을 시각·언어 모델로 교체해, 답변이 항상 정확하지 않은 조건에서의 성능을 평가한다. 비교 조건은 Ours와 KnowNo 두 개로 제한한다. Ours에서 VLM은 선택된 symbolic fact의 참·거짓을 판단하고, KnowNo에서는 제시된 행동 후보 중 다음 행동을 선택한다. 주요 비교 지표는 작업 성공률, 질문 수, VLM 답변 정확도, 오답이 후속 belief와 계획에 미치는 영향이다. 구체적인 모델, prompt, 장면 수, 반복 횟수와 결과 수치는 Oracle 자산과 분리해 보고한다.

Human Evaluation

인간 실험은 5명의 참여자를 대상으로 Ours와 KnowNo를 비교한다. Ours는 참여자에게 관측 가능한 상태 fact를 확인받고 로봇이 다음 행동을 계획한다. KnowNo는 참여자에게 행동 후보를 제시하고 다음 행동을 직접 선택하게 한다. 이 평가의 목적은 소규모 표본으로 일반적인 HRI 우월성을 증명하는 것이 아니라, 두 질문 형식이 요구하는 판단, 응답 난이도, 응답 양상, 후속 계획에 대한 영향을 탐색적으로 비교하는 데 있다.

Reporting Policy

- Oracle 수치는 `latex_zips/latex_auro/asset/BRL_oracle_exp_v2` 내 최신 논문용 패키지만 사용한다. `legacy` 및 이전 parameter 배치는 결과에 포함하지 않는다.
- 성공률은 정상 종료한 실패를 포함한 전체 실행을 분모로 계산한다. Policy ablation의 지정된 파싱 오류 4건도 failure로 집계한다.
- 질문 수와 물리 행동 수는 전체 평균과 성공 episode 평균을 분리한다. 방법 간 효율 비교에서는 조기 실패의 영향을 줄이기 위해 성공 episode 평균을 우선한다.
- 오라클, VLM, 인간 실험은 응답 정확도와 질문 형식이 다르므로 절대 수치를 직접 합치지 않고, 각 실험 내의 Ours-baseline 비교로 해석한다.

Interpretation

행동 후보 기반 방법은 잘못된 상태를 확신한 결과 행동 후보가 하나로 좁혀지면, 실행 전에 정보를 요청해야 할 필요를 감지하지 못할 수 있다. 또한 생성된 행동 후보가 잘못된 상태 추정에 의존하면 진짜 상태에서 필요한 행동이 후보에 포함되지 않을 수 있다.

보상 기반 질의는 원칙적으로 downstream task utility와 질문 비용을 함께 최적화할 수 있지만, 제한된 online search budget에서는 질문의 가치가 몇 단계 뒤에 드러나는 경우 이를 과소평가할 수 있다. 이에 비해 정규화된 entropy는 작업 보상을 직접 최적화하지는 않지만, 현재 frontier의 상태 모호함을 안정적이고 저비용으로 평가하는 실용적 기준을 제공한다.

제안 방법의 이점은 모든 상태 불확실성을 없애는 데 있지 않다. 계획에 영향을 줄 수 있는 도달 가능한 상태 가설들만 구성하고, 그 안에서 실행을 계속하기에 충분한 수준까지만 정보를 획득하는 데 있다.

Contributions

1. 현재 symbolic state의 불확실성에 기반해 언제 질문할지를 결정하며, 적절한 질문 시점이 작업 성공률을 향상시킴을 보인다.
2. 불확실성을 줄일 것으로 기대되는 상태 정보를 우선적으로 질문하며, 정보적인 질문 선택이 필요한 질문 횟수를 줄임을 보인다.
3. 제안 방법을 conformal prediction 기반 및 reward 기반 전략과 비교하며, 질문 횟수를 과도하게 늘리지 않으면서 더 높은 작업 성공률을 달성함을 보인다.

Novelty

차별점은 state query, belief, entropy 중 하나의 요소를 처음 사용했다는 데 있지 않다. 핵심은 외부에 로봇의 행동 결정을 넘기지 않고, 도달 가능한 여러 symbolic world의 확률적 모호함을 질문 시점의 기준으로 사용하며, 그 world들을 가장 잘 구분하는 fact를 질문한 후 갱신된 belief로 다시 계획하는 결합 구조에 있다.

이는 상태 추정이 잘못된 상황에서도 행동 후보만을 비교하는 방법의 한계를 피하고, 작업 보상에서 질문의 장기적 가치를 반복적으로 추정하지 않고도 planning-relevant belief를 정제하는 방법을 제공한다.

Limitations

- 전체 belief를 장기간 전파하지 않고, 매 step에서 MAP state를 선택한 뒤 다음 local frontier를 다시 구성한다. 상태 후보 수도 제한하므로 진실 상태가 후보에서 제거될 수 있다.
- entropy가 높다고 해서 그 불확실성이 반드시 작업 성공에 중요한 것은 아니다. 다른 상태가 같은 행동을 요구할 수 있고, 확률이 낮은 상태가 치명적인 행동 차이를 만들 수도 있다.
- expected entropy reduction은 downstream task reward를 직접 최적화하는 value-of-information 기준이 아니다. 따라서 선택된 질문이 목표 달성에 가장 중요하다는 보장은 없다.
- 질문은 미리 구성된 grounded fact에 대한 binary verification으로 제한된다. Oracle 평가는 외부 답변이 정확하다고 가정하며, VLM과 5명 인간 평가가 이 가정을 완화하는 보완 증거를 제공한다. 그럼에도 모호한 답변, 상태 모델 밖의 새로운 정보, 오답 후 복구를 일반적으로 다루는 메커니즘은 없다.
- 비교 방법들은 질문 형식과 planning 구조가 서로 다르다. 따라서 전체 시스템 비교만으로 특정 질문 기준의 인과적 우월성을 단정할 수 없다.
- 질문 횟수는 측정 가능한 비용이지만, 질문의 해석 난이도나 실제 응답 비용을 완전히 대변하지는 않는다.
- 결과는 폐기물 분류와 토마토 수확, 사용한 전이·관측 오류, 계획 파라미터에 한정된다.

Scope

본 요약은 planning contribution에 집중한다. 논문의 중심은 모듈 구성이나 인터페이스 구현이 아니라, belief에 기반한 선택적 정보 획득과 그 정보를 반영한 재계획이다. 기존 12명 HRI 실험은 제외하고, 새 실험 구성에서 Ours와 KnowNo를 비교하는 5명 인간 평가만을 탐색적 증거로 다룬다.